

Что означает каждый символ

Справочник обозначений курса «Нейронные сети и глубокое обучение»

Темы 1–6: ИНС, Backprop, Обучение, СНС, РНС, Трансформеры

1. Общие обозначения (все темы)

Эти символы встречаются почти в каждой формуле курса — знать их обязательно.

Символ	Называется	Что означает на практике
x	Входной вектор	Входные данные сети: пиксели, признаки объекта, токен. $x = (x_1, x_2, \dots, x_m)$.
y	Выход нейрона / сети	Результат после применения функции активации. $y = f(s)$.
s или S	Взвешенная сумма	То, что поступает на активационную функцию до её применения. $s = w_0 + \sum w_i x_i$. Выход «сумматора».
w или W	Вес / матрица весов	Настраиваемый параметр сети. Скалярный w_i — один вес связи. Матрица W — все веса слоя.
w_0 или b	Смещение (bias)	Свободный член в сумматоре. Сдвигает порог срабатывания нейрона независимо от входа.
f	Функция активации	Нелинейная функция нейрона: сигмоида, $\tanh$, ReLU и т.д. Применяется к сумме s .
d	Желаемый выход	Эталонный (правильный) ответ из обучающей выборки. Сравнивается с фактическим выходом y .
L	Функция потерь	Мера расхождения между d и y . То, что минимизируем при обучении (MSE, кросс-энтропия).
λ (лямбда)	Скорость обучения	Learning rate. Насколько сильно менять веса за один шаг. Слишком большая → расходимость, слишком малая → медленно.
n	Номер слоя	Индекс слоя сети. $n=0$ — вход, $n=N$ — выход. Используется в верхнем индексе: y^n , w^n .
N	Число слоёв	Общее количество слоёв сети (не считая входного). Выходной слой — N -й.
i, j	Индексы нейронов	i — номер нейрона предыдущего слоя, j — нейрона текущего. w_{ij} — вес связи от i к j .
Nb	Объём выборки	Количество примеров в обучающей выборке.

2. Тема 1–2: Формальный нейрон и Backprop

Формулы вида $y_j^n = f(S_j^n)$ и $g_j^n = y(1-y)(d-y)$

Символ	Называется	Что означает на практике
y_j^n	Выход j -го нейрона слоя n	Итог работы нейрона j в слое n . Верхний индекс n = слой, нижний j = номер нейрона.

Символ	Называется	Что означает на практике
y_j^0	Входной сигнал j	Выход «нулевого слоя» = просто входные данные x_j . Обозначает, что вход — тоже вектор.
y^N	Выход всей сети	Выходные значения последнего (N-го) слоя. Это финальный ответ сети.
w_{ij}^n	Вес связи $i \rightarrow j$ в слое n	Насколько нейрон i предыдущего слоя влияет на нейрон j текущего. Верхний n — слой, нижние i, j — откуда/куда.
S_j^n	Взвешенная сумма нейрона j	Сумма всех взвешенных входов: $S_j^n = \sum_i w_{ij}^n \cdot y_i^{n-1}$. Это аргумент функции активации.
g_j^n или δ_j^n	«Дельта» нейрона j в слое n	Ошибка или чувствительность потерь к S_j^n . Вычисляется при обратном проходе. Через неё считается поправка веса.
$f'(s)$	Производная активации	Наклон функции активации в точке s . Нужна при обратном проходе. Для сигмоиды: $f(s) \cdot (1 - f(s))$. Для $\tanh$: $1 - \tanh^2(s)$.
d_j	Эталонный выход j -го нейрона	Правильный ответ для j -го выхода сети. Разность $(d_j - y_j)$ — ошибка на выходном слое.
$\lambda \cdot g_j \cdot y_i$	Поправка к весу	На сколько меняется вес w_{ij} за один шаг. Чем больше ошибка g_j и активация входа y_i — тем больше поправка.
$\partial L / \partial w$	Градиент потерь по весу	Направление наискорейшего роста потерь. Веса движутся в противоположном направлении $(-\lambda \cdot \partial L / \partial w)$.

3. Тема 3: Оптимизаторы и регуляризация

Формулы вида $v \leftarrow \beta \cdot v - \lambda \cdot g$; $w \leftarrow w + v$

Символ	Называется	Что означает на практике
∇L или g	Градиент потерь	Вектор частных производных функции потерь по всем весам. Показывает направление роста потерь.
β (бета)	Коэффициент момента	В Momentum и Adam. Обычно $\beta \approx 0.9$. Насколько «помним» прошлые градиенты. Ближе к 1 — больше инерции.
β_1	Момент 1-го порядка (Adam)	Коэффициент экспоненциального среднего самого градиента (обычно 0.9). Отвечает за «скорость» движения.
β_2	Момент 2-го порядка (Adam)	Коэффициент среднего квадрата градиента (обычно 0.999). Отвечает за «адаптивный масштаб» шага.
v	Импульс (velocity)	Накопленная «инерция» движения в пространстве весов. Обновляется как $v \leftarrow \beta \cdot v - \lambda \cdot g$.
m	1-й момент в Adam	Экспоненциальное среднее градиентов: $m = \beta_1 \cdot m + (1 - \beta_1) \cdot g$. Оценка «куда движемся».
v	2-й момент в Adam	Экспоненциальное среднее квадратов градиентов: $v = \beta_2 \cdot v + (1 - \beta_2) \cdot g^2$. Оценка «насколько прыгаем».
$\hat{m}, \hat{v}$	Скорректированные моменты	В начале обучения m и v смещены к нулю (начали с нуля). Деление на $(1 - \beta^t)$ исправляет это смещение.
ϵ (эпсилон)	Малая константа	Добавляется в знаменатель Adam $(\sqrt{\hat{v}} + \epsilon)$ для численной стабильности. Обычно $\approx 10^{-8}$. Защищает от деления на 0.
α (альфа)	Коэффициент регуляризации	Сила L1 или L2 штрафа. Насколько сильно «тянем» веса к нулю. Чем больше α , тем меньше переобучение (но и хуже качество).

Символ	Называется	Что означает на практике
γ (гамма)	Масштаб в BatchNorm	Обучаемый параметр пакетной нормализации. Позволяет сети «отменить» нормализацию, если нужно.
β (бета в BatchNorm)	Сдвиг в BatchNorm	Обучаемый сдвиг в BatchNorm. Вместе с γ восстанавливает нужное распределение активаций.
μ (мю)	Среднее по батчу	Математическое ожидание активаций в мини-батче. Вычитается при нормализации: $(x - \mu)$.
σ^2 (сигма ²)	Дисперсия по батчу	Разброс активаций в мини-батче. Используется для нормировки: $(x - \mu) / \sqrt{(\sigma^2 + \epsilon)}$.
p	Вероятность Dropout	Вероятность «выключить» нейрон при обучении (обычно 0.2–0.5). При инференсе умножают выходы на $(1-p)$.
t	Номер шага оптимизации	Счётчик шагов обучения. Используется в коррекции Adam: делим на $(1-\beta^t)$. С ростом t коррекция убывает.

4. Тема 4: Свёрточные нейронные сети (СНС)

Формулы вида $s(n_1, n_2) = \sum w(m) \cdot x(n+m)$, $\text{выход} = (N-M+1)$

Символ	Называется	Что означает на практике
N_1, N_2	Пространственные размеры входа	Высота и ширина входного тензора (изображения). Например, 224×224 для ImageNet.
M_1, M_2	Размеры ядра (фильтра)	Высота и ширина фильтра свёртки. Типично: 3×3, 5×5, 7×7. Чем больше ядро — шире поле восприятия.
K	Число каналов (глубина) входа	Количество карт признаков на входе свёрточного слоя. Для RGB-изображения $K=3$.
L	Число фильтров (ядер) в слое	Сколько разных фильтров применяется к входу. = числу карт признаков на выходе слоя.
P, P_1, P_2	Дополнение (padding)	Сколько нулей добавляется по краям перед свёрткой. При $P = M-1$ выход = вход (конгруэнтная свёртка).
n_1, n_2	Пространственная позиция выхода	Координаты точки в выходном тензоре. По этим координатам «сдвигается» ядро.
m_1, m_2	Смещение внутри ядра	Координаты элемента внутри фильтра при свёртке. Суммирование идёт по всем m_1, m_2 .
k	Индекс канала	Номер канала при суммировании по глубине. В свёртке суммируем по всем k от 1 до K .
$F(x)$	Остаточная функция (ResNet)	То, чему обучается блок ResNet. Полный выход: $y = F(x) + x$. Сети проще обучить «остаток», чем всё отображение.
x	Вход блока ResNet	Входной тензор в блок. Передаётся напрямую через skip-соединение и складывается с $F(x)$.
d	Коэффициент дырявости (dilated)	В дырявой свёртке: шаг между отсчётами ядра. $d=1$ — обычная свёртка, $d=2$ — через один пиксель. Расширяет поле восприятия.
h_q, φ_{pq}	Функции в теореме Колмогорова	h_q — внешние функции (зависят от задачи), φ_{pq} — стандартные внутренние функции (одинаковые для любой f).

5. Тема 5: Рекуррентные нейронные сети (РНС)

Формулы вида $h(t) = f(W_{hh} \cdot h(t-1) + W_{xh} \cdot x(t) + b)$

Символ	Называется	Что означает на практике
t	Дискретный момент времени	Шаг последовательности: $t = 0, 1, 2, \dots, T-1$. Каждое $x(t)$ — один элемент последовательности (слово, токен, пиксель).
$x(t)$	Вход в момент t	Текущий элемент последовательности. Например, эмбединг слова на шаге t .
$h(t)$	Скрытое состояние в момент t	Вектор «памяти» сети. Хранит информацию о всех предыдущих элементах последовательности. Передаётся на следующий шаг.
$h(t-1)$	Предыдущее скрытое состояние	Состояние на шаге $t-1$. Через него в сеть поступает информация о прошлом.
$y(t)$	Выход сети в момент t	Предсказание сети на шаге t (например, вероятность следующего слова).
W_{hh}	Матрица рекуррентных весов	Как предыдущее состояние $h(t-1)$ влияет на текущее. Главный «виновник» затухания/взрыва градиентов (возводится в степень T).
W_{xh}	Матрица вход→состояние	Как текущий вход $x(t)$ влияет на скрытое состояние $h(t)$.
W_{hy}	Матрица состояние→выход	Как скрытое состояние $h(t)$ преобразуется в выходной вектор $y(t)$.
$c(t)$	Ячейка памяти (LSTM)	Вектор долгосрочной памяти в LSTM. Обновляется аддитивно — информация может «храниться» очень долго.
$\tilde{c}(t)$	Кандидат новой ячейки	Предложение для новой информации в ячейку $c(t)$. Вычисляется через $\tanh$. Входной вентиль i определяет, сколько взять.
$\tilde{h}(t)$	Кандидат нового состояния (GRU)	Предложение для нового $h(t)$ в GRU. Вентиль z определяет, сколько взять от $\tilde{h}(t)$, а сколько оставить от $h(t-1)$.
$r(t)$	Вентиль сброса (GRU)	Значения в $(0,1)$. Близко к 0 — «забыть» прошлое состояние, использовать только текущий вход. Краткосрочная память.
$z(t)$	Вентиль обновления (GRU)	Значения в $(0,1)$. Близко к 1 — полностью сохранить старое $h(t-1)$. Близко к 0 — полностью взять кандидата $\tilde{h}(t)$.
$i(t)$	Входной вентиль (LSTM)	Сколько кандидата $\tilde{c}(t)$ добавить в ячейку. Значения в $(0,1)$.
$f(t)$	Вентиль забывания (LSTM)	Сколько старой ячейки $c(t-1)$ оставить. $f=1$ — полностью помнить (бесконечная память), $f=0$ — полностью забыть.
$o(t)$	Выходной вентиль (LSTM)	Сколько информации из ячейки $c(t)$ «прочитать» в $h(t)$. Фильтрует, что попадает в скрытое состояние.
σ (сигма)	Функция сигмоиды	Применяется ко всем вентилям GRU и LSTM. Выдаёт значения $(0,1)$ — интерпретируются как «степень открытия вентиля».
$\circ$	Произведение Адамара	Позлементное умножение векторов: $[a_1, a_2, \dots] \circ [b_1, b_2, \dots] = [a_1 b_1, a_2 b_2, \dots]$. Вентили «масштабируют» каждую компоненту отдельно.

Символ	Называется	Что означает на практике
T (температура)	Параметр температуры	Масштаб логитов перед softmax при генерации. $T > 1 \rightarrow$ вероятности выровнены $\rightarrow$ разнообразнее. $T < 1 \rightarrow$ одна вершина острее $\rightarrow$ предсказуемее.

6. Тема 6: Трансформеры

Формулы вида $SDPA(Q,K,V) = \text{SoftMax}(KQ^T / \sqrt{d}) \cdot V$

Символ	Называется	Что означает на практике
Q	Запросы (Queries)	Что ищем. Матрица запросов: каждая строка — запрос одного токена/позиции. «С чем сравнивать?»
K	Ключи (Keys)	С чем сравниваем запросы. Каждый токен «предлагает» свой ключ. «На что откликаться?»
V	Значения (Values)	Что извлекаем при совпадении. Если ключ K близок к запросу Q — берём соответствующее V .
d	Размерность модели	Ширина представления токена в трансформере. В оригинале $d = 512$. Проходит через все слои.
d_K	Размерность ключа/запроса	Размерность подпространства одной «головы». В оригинале $d_K = 64$. Связь: $d_K \cdot h = d$.
d_V	Размерность значения	Размерность значения в одной голове. Обычно $d_V = d_K$. Связь: $d_V \cdot h = d$.
h	Число голов (heads)	Сколько независимых механизмов внимания работает параллельно. В оригинале $h = 8$. Каждая голова учит свои паттерны.
$\sqrt{d}$	Масштабирующий делитель	Корень из размерности d_K . Делим скалярные произведения на $\sqrt{d}$, чтобы softmax не «заострялся» и не терял градиент.
W^Q, W^K, W^V	Матрицы проекций	Обучаемые матрицы, проецирующие входной тензор в пространство запросов, ключей и значений для каждой головы.
W^O	Выходная матрица МНА	Обучаемая матрица, объединяющая результаты всех h голов в один тензор размерности d .
N (в трансф.)	Число блоков	Количество повторяющихся блоков кодера/декодера. В базовом трансформере $N = 6$.
d_{ff}	Размерность скрытого слоя FFN	Ширина внутреннего слоя позиционной сети прямого распространения. В оригинале $d_{ff} = 2048 = 4 \cdot d$.
p_i	Позиционный код позиции i	Вектор, кодирующий номер позиции токена в последовательности. Прибавляется к эмбедингу: $x_i = x_i^{in} + p_i$.
R	База позиционного кодирования	Основание в формуле синусоидального кодирования. $R = 10000$ в оригинале. Определяет диапазон частот.
E	Матрица выходов кодера	Все n векторов, которые кодер выдал для входной последовательности. Используется в кросс-внимании декодера как K и V .
$e_1..e_n$	Представления кодера	n выходных векторов кодера. Каждый e_i — «обогащённый контекстом» вектор i -го входного токена.

Символ	Называется	Что означает на практике
b^{in}	One-hot вектор токена	Индикаторный вектор: единица на позиции токена в словаре, остальное — нули. Умножается на W^{in} для получения эмбединга.
W^{in}	Матрица эмбедингов	Таблица векторных представлений всех токенов. Строка $W^{in}[i]$ — эмбединг i-го токена словаря.
PPL	Перплексия (perplexity)	Метрика качества языковой модели. $PPL = \exp(-\text{среднее } \log\text{-вероятности токенов})$. Меньше → лучше. $PPL=k$ означает: модель «выбирает из k равновероятных вариантов».
$-\infty$	Маска в Masked Attention	Добавляется к запрещённым позициям перед softmax. После softmax: $\exp(-\infty) = 0 \rightarrow$ вес позиции = 0 → токен «не видит» будущее.
$[SOS]$	Стартовый токен	Специальный токен Start of Sequence. Подаётся декодеру первым как сигнал начать генерацию.
$[EOS]$	Конечный токен	End of Sequence. Когда декодер предсказывает $[EOS]$, генерация останавливается.

7. Греческие буквы и спецсимволы

Быстрый справочник по всем греческим буквам курса

Символ	Называется	Что означает на практике
λ (лямбда)	Learning rate	Скорость обучения. Размер шага при обновлении весов. Самый важный гиперпараметр.
α (альфа)	Коэффициент регуляризации	Сила L1/L2 штрафа. Также иногда: learning rate в некоторых нотациях.
β (бета)	Момент / коэффициент	Коэффициент Momentum ($\beta \approx 0.9$), или β_1, β_2 в Adam. Также смещение в BatchNorm.
γ (гамма)	Масштаб / коэф. сжатия	Масштаб в BatchNorm. В DenseNet: θ (тета) — коэффициент сжатия между блоками.
δ (дельта)	Ошибка нейрона	То же, что g в обозначениях backprop. Чувствительность потерь к аргументу активации.
ϵ (эпсилон)	Малая константа	Численная стабильность в Adam ($\approx 10^{-8}$). Также: небольшое смещение в BatchNorm.
σ (сигма)	Сигмоида / стандартное отклонение	$1/(1+e^{-s})$ — функция сигмоиды (также для вентилей GRU/LSTM). σ^2 — дисперсия в BatchNorm.
μ (мю)	Среднее	Среднее значение активаций по батчу в BatchNorm.
θ (тета)	Коэффициент сжатия (DenseNet)	В DenseNet $\theta \in (0,1]$: переходный слой оставляет $\theta \cdot M$ карт признаков от M карт предыдущего блока.
∇ (набла)	Оператор градиента	∇L = вектор всех частных производных L по весам. «Направление роста потерь».
∂ (дифф)	Частная производная	$\partial L / \partial w$ — насколько изменится L при малом изменении веса w , при фиксированных остальных.
$\circ$ (кружок)	Произведение Адамара	Поэлементное умножение векторов (GRU, LSTM). НЕ матричное произведение!

Символ	Называется	Что означает на практике
Σ (сигма большая)	Сумма	Суммирование по индексу. $\sum_i w_i x_i = w_1 x_1 + w_2 x_2 + \dots$ Основа сумматора нейрона.
π (пи)	Перестановка	В свойствах SDPA: $\pi(Q)$ — перестановка строк матрицы Q . SDPA эквивариантен по Q и инвариантен по (K, V) .